



UNIVERSITA' DEGLI STUDI DI
NAPOLI FEDERICO II

Scuola Politecnica e delle Scienze di Base
Corso di Laurea Magistrale in Ingegneria Informatica

Homework 2 - Big Data Engineering

Clinical Trials Dataset (MongoDB and Neo4j Analytics)

Anno Accademico 2024/2025

Professore
prof. Vincenzo Moscato

Candidati
Vincenzo Luigi Bruno matr. M63001670
Salvatore Cangiano matr. M63001647

Contents

1	Dataset e Preprocessing	1
1.1	Database e Servizi Cloud Utilizzati	1
1.2	Descrizione del Dataset	2
1.3	Preprocessing	5
1.3.1	Conversione Liste	5
1.3.2	Conversione età	6
2	Analytics	8
2.1	Numero di studi avviati per anno	8
2.1.1	Implementazione della query	8
2.1.2	Risultati	9
2.2	Numero medio di partecipanti per studio	12
2.2.1	Implementazione della query	12
2.2.2	Risultati	12
2.3	Top 10 condizioni mediche più studiate	14
2.3.1	Implementazione della Query	14
2.3.2	Risultati	16
2.4	Nazione con la media di partecipanti più alta, per tipo di studio . .	18
2.4.1	Implementazione della query	18
2.4.2	Risultati	19
2.5	Città che hanno trattato maggiormente una determinata condizione	20
2.5.1	Implementazione della query	20
2.5.2	Risultati	23

2.6	Nazioni che sponsorizzano il maggior numero di studi clinici rivolti alle donne	24
2.6.1	Implementazione della query	24
2.6.2	Risultati	25
2.7	Nazioni che sponsorizzano il maggior numero di studi che coinvolgono minori	26
2.7.1	Implementazione della query	26
2.7.2	Risultati	27
2.8	Città che ricercano più attivamente uno specifico tipo di cancro . .	29
2.8.1	Implementazione della query	29
2.8.2	Risultati	30
2.9	Studi clinici che si sono conclusi, con relative condizioni mediche trattate	32
2.9.1	Implementazione della query	32
2.9.2	Risultati	33
2.10	Studi clinici con maggiore visibilità mediatica (Altmetric score) . .	34
2.10.1	Implementazione della query	34
2.10.2	Risultati	37
2.11	Condizioni con media più alta di Altmetric Score	38
2.11.1	Implementazione della query	38
2.11.2	Risultati	39
2.12	Nazioni delle organizzazioni finanziatrici che hanno sponsorizzato il maggior numero di studi clinici	40
2.12.1	Implementazione della query	40
2.12.2	Risultati	42
2.13	Ricercatori/Contatti più attivi con relativa patologia più studiata .	44
2.13.1	Implementazione della query	44
2.13.2	Risultati	44
2.14	Top collaborazioni dell'Università di Napoli Federico II con enti finanziatori	45

2.14.1	Implementazione della query	45
2.14.2	Risultati	47
2.15	Top collaborazione per ente finanziatore	50
2.15.1	Implementazione della query	50
2.15.2	Risultati	50

Chapter 1

Dataset e Preprocessing

1.1 Database e Servizi Cloud Utilizzati

Le tecnologie con cui andremo a lavorare sono due database **NoSQL**, in particolare un database Documentale, ossia **MongoDB** e un database a grafo, **Neo4J**.

Per poter impostare il lavoro anche per una mole di dati maggiore, e anche per parallelizzare meglio il lavoro in gruppo, sono stati utilizzati i servizi cloud associati alle varie tecnologie:

- Mongo DB Atlas
- Neo4j Aura

Purtroppo però per mancanza di fondi, le soluzioni free che questi servizi offrono presentano molte limitazioni, in termini di potenza computazionale e soprattutto di storage. Questo ci ha costretto ad utilizzare solo una sottoparte del dataset originale.

1.2 Descrizione del Dataset

Il dataset utilizzato in questo esercizio proviene da *Dimensions.ai*, una piattaforma che aggrega dati relativi alla ricerca scientifica a livello globale. Ogni riga del dataset rappresenta uno *studio clinico* (clinical trial), contenente informazioni strutturate riguardanti l'identificativo, i dettagli dello studio, i soggetti coinvolti, le condizioni mediche trattate, nonché dati su sponsor, finanziatori e metriche di impatto.

I campi del dataset sono:

1. **Rank**: posizione numerica o classifica assegnata a ciascun trial.
2. **Trial ID**: identificatore univoco del trial clinico.
3. **Title**: titolo completo del trial
4. **Brief title**: titolo breve o sintetico del trial.
5. **Acronym**: acronimo associato al trial (se disponibile).
6. **Abstract**: sommario o sinossi dello studio, con obiettivi, metodologia e risultati principali (se disponibili).
7. **Start date**: data di inizio del trial clinico.
8. **Start Year**: anno in cui è iniziato il trial.
9. **End Date**: data di fine prevista o effettva dello studio.
10. **Completion Year**: anno di completamento del trial.
11. **Phase**: fase dello studio clinico (1-4).
12. **Study Type**: tipo di studio (es. Interventistico, Osservazionale).
13. **Study Design**: descrizione del progetto sperimentale.

14. **Conditions:** elenco delle patologie o condizioni mediche esaminate.
15. **Recruitment Status:** stato del reclutamento dei partecipanti (es. in corso, completato, terminato anticipatamente).
16. **Number of Participants:** numero previsto o reale di partecipanti coinvolti.
17. **Intervention:** descrizione dell'intervento.
18. **Gender:** genere dei partecipanti target (maschi, femmine, entrambi).
19. **Age:** fasce d'età dei partecipanti coinvolti.
20. **Registry:** nome del registro dove è registrato il trial (es. ClinicalTrials.gov).
21. **Investigators/Contacts:** informazioni sui principali ricercatori e/o contatti associati allo studio.
22. **Sponsors/Collaborators:** enti o organizzazioni che sponsorizzano e/o collaborano allo studio.
23. **City of Sponsor/Collaborator:** città associata allo sponsor o collaboratore.
24. **State of Sponsor/Collaborator:** stato o provincia dello sponsor/collaboratore.
25. **Country of Sponsor/Collaborator:** paese dello sponsor/collaboratore.
26. **Collaborating Funders:** altri enti finanziatori che collaborano al trial.
27. **Funder Group:** gruppi o categorie di appartenenza degli enti finanziatori.
28. **Funder Country:** paesi di origine degli enti finanziatori.
29. **Source Linkout:** link esterno alla fonte originale o scheda ufficiale dello studio.

30. **Altmetric Attention Score**: punteggio che misura l'attenzione mediatica ricevuta (social media, news, blog).
31. **Dimension URL**: link alla piattaforma Dimensions.ai (per metadati e metriche bibliometriche).
32. **Fields of Research (ANZSRC 2020)**: aree di ricerca secondo la classificazione ANZSRC 2020 (Australian & New Zealand Standard Research Classification).
33. **RCDC Categories**: categorie di ricerca secondo il sistema RCDC (Research, Condition, and Disease Categorization) del NIH.
34. **HRCS HC Categories**: categorie sanitarie secondo il sistema HRCS (UK Health Research Classification System) – Health Categories.
35. **HRCS RAC Categories**: Categorie di allocazione delle risorse secondo HRCS – Research Activity Codes.
36. **Cancer Types**: tipi di cancro studiati (se applicabile).
37. **CSO Categories**: categorie secondo il sistema CSO (Common Scientific Outline), usato nella ricerca sul cancro.
38. **AHC**: informazioni relative ai Centri Accademici di Salute (Academic Health Centers), se disponibili.

Questo dataset consente un'analisi multidimensionale della ricerca clinica globale, includendo aspetti scientifici, organizzativi e sociali dei trial.

Il dataset presenta quindi **38 colonne e 15990 righe**.


1.3 Preprocessing

Molte colonne del dataset si presentano in un formato **pseudo-strutturato**. Ad esempio il campo **Condition** è una stringa di molte condizioni separate dal carattere ";". Di fatto le colonne come Condition, non sono esplicitamente formattate con il Type che esse vogliono rappresentare. PySpark però mette a disposizione la possibilità di assegnare campi strutturati come **ArrayList** per le liste e **MapType** per i dizionari, pertanto per semplificare il processo di analisi e implementazione delle query si è deciso di convertire il tipo di queste colonne.

<i>List</i>	Conditions
	Investigators/Contacts
	Sponsors/Collaborators
	City of Sponsor/Collaborator
	State of Sponsor/Collaborator
<i>List of two elements</i>	Country of Sponsor/Collaborator
	Fields of Research (ANZSRC 2020)
	Collaborating Funders
	Funder Group
	Funder Country
	RCDC Categories
	HRCS HC Categories
	HRCS RAC Categories
	Cancer Types
	CSO Categories
	Age

1.3.1 Conversione Liste

Le colonne che sono pseudo-liste sono stringhe di valori separati dal carattere ;. Tutte le colonne con questo comportamento sono state elencate nella precedente tabella degli pseudo tipi. La conversione è stata fatta creando una lista python di valori per ogni colonna interessata, per poi utilizzare la stessa lista nel caricamento dei dati nel relativo DB:



```
#Example of List Conversion
def split_field(value, delimiter=","):
    if not value:
        return []

    return [item.strip() for item in value.split(delimiter)]

funder_groups = split_field_to_array(row_data.get("Funder Group", ""))
```

Figure 1.1: Implementazione conversione Liste a ArrayType

1.3.2 Conversione età

Il campo età ha subito ha una struttura peculiare che ha necessitato di una trasformazione più complessa. Si presenta come una stringa, che rappresenta l'**età minima** per partecipare al clinical trial e l'**età massima**. Il problema principale è che possiamo avere situazioni in cui il minimo e il massimo sono entrambi in formato **Years**, ma anche in formato **Month** oppure **Days**. Si è deciso quindi di includere nella trasformazione anche un processo di conversione di tutti formati al singolo formato **Years**. In particolare:

1. La funzione divide in parti la stringa passata utilizzando come delimitatore il carattere "-"
2. Definiamo una funzione interna `convert_to_years` che:
 - Estrae il valore numerico e l'unità (anni, mesi, settimane, giorni, ore) da una parte della stringa
 - Converte tutto in equivalente anni.
 - Gestisce anche i "n/a" all'interno delle singole parti
3. Applica la conversione all'età minima (se presente) e all'età massima (se presente) ottenute dalla divisione della stringa iniziale.

```
#Example of Age Conversion
def parse_age(age_string):

    if not age_string or age_string.strip().lower() == "n/a - n/a":
        return [None, None]

    min_age, max_age = None, None
    parts = [p.strip() for p in age_string.split('--')]

    def convert_to_years(value_part_str):
        if "n/a" in value_part_str.lower():
            return None

        num_match = re.search(r'(\d+\.?\d*)\s*(year|years|month|months|week|weeks|day|days|hour|hours)',
                               value_part_str, re.IGNORECASE)
        if not num_match:
            return None

        num = float(num_match.group(1))
        unit = num_match.group(2).lower()

        if "year" in unit:
            return num
        elif "month" in unit:
            return num / 12
        elif "week" in unit:
            return num / 52
        elif "day" in unit:
            return num / 365
        elif "hour" in unit:
            return num / (365 * 24)
        return None

    if len(parts) > 0:
        min_age = convert_to_years(parts[0])
    if len(parts) > 1:
        max_age = convert_to_years(parts[1])

    return [min_age, max_age]

age_min_max = parse_age(row_data.get("Age", ""))
```

Figure 1.2: Implementazione conversione età in formato ArrayType di FloatType

Chapter 2

Analytics

2.1 Numero di studi avviati per anno

2.1.1 Implementazione della query

L'obiettivo della query è analizzare quanti **studi clinici** sono stati **iniziati per ogni anno**.

In particolare:

- Si filtrano i dati per anno di inizio non nullo.
- Si raggruppano i dati per anno di inizio (*Start Year*).
- Si conteggiano gli studi per ciascun anno.
- Si ordina il risultato in ordine decrescente.

Gli stessi passaggi vengono fatti, ma tradotti in linguaggio pymongo e cypher.

Viene anche riportato il primo grafo, per questa query non è molto illuminante ma è un esempio di come si possa creare ed esportare il grafo tramite AuraDB. Ecco l'implementazione della query n1 per ottenere un grafico:

```

pipeline_1 = [
    {
        "$match": {
            "start_year": {"$ne": None}
        }
    },
    {
        "$group": {
            "_id": "$start_year",
            "num_studies": {"$sum": 1}
        }
    },
    {
        "$sort": {"_id": 1}
    }
]
result_1 = list(collection.aggregate(pipeline_1))

if result_1:
    df_1 = pd.DataFrame(result_1)
    df_1.rename(columns={'_id': 'Anno', 'num_studies': 'Numero Studi'}, inplace=True)

    print(df_1)
else:
    print("Nessun risultato")

csv_1 = "mongo_1.csv"
df_1.to_csv(csv_1, index=False, encoding='utf-8-sig')

```

Figure 2.1: Numero di studi avviati per anno pymongo

```

query_n1 = """
MATCH (ct: ClinicalTrial)
WHERE ct.StartYear IS NOT NULL
RETURN ct.StartYear AS `Start Year`, count(ct) AS `NumStudies per Year`
ORDER BY `NumStudies per Year` DESC
LIMIT 50
"""

df_n1, error = get_results_analytics(driver, query_n1)

if error:
    print("Ripetere la query n1, df vuoto")
else:
    if not os.path.exists(result_path):
        os.makedirs(result_path)
    df_n1.to_csv(f"{result_path}/results_neo4j_n1.csv", index=False)
    print("Risultati query n1 salvati in csv")

```

Figure 2.2: Numero di studi avviati per anno cypher

2.1.2 Risultati

Dalla tabella risultante è possibile osservare alcuni trend:

- Il maggior numero di studi si è registrato negli anni 2019-2021.
- Vi è un calo nel numero di studi invece nel periodo successivo (2023-2025) che può essere parzialmente spiegato dal fatto che i dati potrebbero essere

```

query_graph_n1 = """
MATCH (ct: ClinicalTrial)
WHERE ct.StartYear IS NOT NULL
RETURN ct // Questo restituisce i nodi 'ClinicalTrial'
LIMIT 100 // È cruciale limitare il numero di nodi per la visualizzazione
"""

graph, error = get_graph_analytics(driver, query_graph_n1)

if error:
    print("Ripetere la query n1, graph vuoto")
else:
    if not os.path.exists(os.path.join(result_path, "graphs")):
        os.makedirs(os.path.join(result_path, "graphs"))
    save_graph(graph, 1)

```

Figure 2.3: Numero di studi avviati per anno grafo




Figure 2.4: Numero di studi avviati per anno grafo

incompleti o ancora **in aggiornamento**.

- Anni precedenti al 2000: pochissimi studi, probabilmente perché la raccolta digitale dei dati era limitata o ancora assente.

Questa analitica è utile poiché permette di identificare periodi di maggiore attività nella ricerca clinica e valutare l'impatto degli eventi globali, come ad esempio, l'incremento negli anni 2020-2021 che può essere legato alla pandemia COVID-19 e alla corsa alla sperimentazione clinica.




Figure 2.5: Line Plot

Start Year	NumStudies per Year
2021.0	453
2020.0	421
2019.0	406
2022.0	368
2017.0	349
2015.0	28
2016.0	283
2023.0	242
2012.0	242
2014.0	233
2013.0	215
2011.0	193
2010.0	173
2009.0	159
2008.0	149


2.2 Numero medio di partecipanti per studio

2.2.1 Implementazione della query

L'obiettivo di questa analitica è calcolare il **numero medio di partecipanti** per ogni **studio** (identificato dal suo *Titolo*)

In particolare:

- Ci si assicura che il titolo e il numero di partecipanti esistano
- Si raggruppa per titolo e si fa la media sul numero di partecipanti



```
MATCH (ct: ClinicalTrial)
WHERE ct.Title IS NOT NULL AND ct.NumberOfParticipants IS NOT NULL
RETURN ct.Title AS `Title`, avg(ct.NumberOfParticipants) AS `AvgParticipants per
Titolo` ORDER BY `AvgParticipants per Titolo` DESC
LIMIT 20
```

Figure 2.6: Numero medio di partecipanti per studio - Cypher

2.2.2 Risultati

Questa analitica è utile per individuare gli studi di grande impatto, dato che spesso gli studi con un elevato numero medio di partecipanti sono associati a **grande rilevanza clinica ed impatto sanitario**.

In particolare osserviamo che i primi due studi che hanno più partecipanti in media sono legati alla pandemia di COVID-19, in particolare sono studi osservazionali di vasta scala e monitoraggi post-vaccinazione.

```

pipeline_2 = [
  {
    "$match": {
      "title": {"$ne": None},
      "number_of_participants": {"$ne": None}
    }
  },
  {
    "$group": {
      "_id": "$title",
      "avg_participants": {"$avg":
"$number_of_participants"}
    },
    {
      "$sort": {"avg_participants": -1}
    },
    {
      "$limit": 20
    }
  }
]
results_2 = list(collection.aggregate(pipeline_2))

```

Figure 2.7: Numero medio di partecipanti per studio - Mongo




Figure 2.8: Bar Chart Orizzontale

Titolo Studio	Media Partecipanti
The epidemiology, severity, and outcomes of children presenting to emergency departments across Europe during the SARS-CoV-2 pandemic: the EPISODES study	240000.0
ACCESS template protocol for safety of COVID-19 vaccines	100000.0
Computerized Registry of Patients With Venous Thromboembolism (RIETE)	120000.0
Effect of Pharmacist Involvement on Patient Reporting of Adverse Drug Reactions: A Multiregional Italian Study	115000.0
What is the Best Interval to Screen Women 45-49 and 70-74 for Breast Cancer	60000.0
Cohort Event Monitoring of safety of COVID-19 vaccines in special populations (pregnant and lactating women, children and adolescents, immunocompromised, people with history of allergy, people with prior SARS-CoV-2 infection)	60000.0
International Randomized Study Comparing Personalized, Risk-Stratified to Standard Breast Cancer Screening in Women Aged 40-70	53142.0
Prospective Evaluation of the European Society of Cardiology 0-1-hour Algorithm's Safety and Efficacy for Triage of Patients With Suspected Myocardial Infarction (PRESCISE-MI)	52156.0
DianaWeb: Before and After Study Online Based Participatory Research to Test Whether Lifestyle and Diet Are Able to Reduce the Incidence of Recurrences (Local, Remote) or Secondary Cancers, Improve Prognosis and Survival of Breast Cancer	50000.0
A Multicentre, Cross-sectional Study to Characterize the Distribution of Lipoprotein(a) Levels Among Patients With Documented History of Atherosclerotic Cardiovascular Disease	35480.0

2.3 Top 10 condizioni mediche più studiate

2.3.1 Implementazione della Query

Questa analitica serve a determinare le **10 condizioni mediche più frequentemente studiate**.

In particolare:

- Si "esplode" l'array di condizioni.
- Si escludono condizioni vuote o nulle dopo l'unwind.
- Si raggruppa per il campo "conditions" e si fa il conteggio.
- Si ordina per conteggio in modo decrescente.

```

MATCH (ct: ClinicalTrial)-[r: HAS_CONDITION]-(c: Condition)
WHERE c.name IS NOT NULL
RETURN c.name AS `Condition Name`, count(r) AS `Count per
Condition`
ORDER BY `Count per Condition` DESC
LIMIT 10

```

Figure 2.9: Top 10 condizioni mediche più studiate - Cypher

```
pipeline_3 = [  
  {  
    "$unwind": "$conditions"  
  },  
  {  
    "$match": {  
      "conditions": {"$ne": None, "$ne": ""}  
    }  
  },  
  {  
    "$group": {  
      "_id": "$conditions",  
      "count": {"$sum": 1}  
    }  
  },  
  {  
    "$sort": {"count": -1}  
  },  
  {  
    "$limit": 10  
  }  
]
```

Figure 2.10: Top 10 condizioni mediche più studiate - Mongo

Di questa query è stato anche estratto un grafico in quanto si può apprezzare come le condizioni più studiate siano un polo di aggregazione per dei clinical trial.

```

query_graph_n3 = """
MATCH (ct:ClinicalTrial)-[r:HAS_CONDITION]-(c:Condition)
WHERE c.name IS NOT NULL
WITH c, count(r) AS relCount, collect({ct: ct, r: r}) AS relationshipsAndTrials
ORDER BY relCount DESC
UNWIND relationshipsAndTrials AS item
LIMIT 400
RETURN item.ct, item.r, c
"""

graph_n3, error = get_graph_analytics(driver, query_graph_n3)

if error:
    print("Ripetere la query n3, graph vuoto")
else:
    save_graph(graph_n3, 3)

```

Figure 2.11: Top 10 condizioni mediche più studiate - Implementazione Grafo




Figure 2.12: Top 10 condizioni mediche più studiate - Grafo

2.3.2 Risultati

Notiamo come ci sia forte interesse clinico e di ricerca nelle condizioni di *cancro al seno* o *mieloma multiplo* e che ben 4 delle 10 condizioni rientrano nell'ambito oncologico:

- *Breast, lung, melanoma, prostate.*

Ciò conferma la centralità del **cancro** nella ricerca biomedica per impatto, complessità ed investimento.

Quest'analitica è utile ai ricercatori e enti finanziatori come supporto alla pianificazione strategica della ricerca, dato che è molto semplice identificare le aree




Figure 2.13: Top 10 condizioni mediche più studiate

di alta concentrazione di studi in maniera tale da evitare duplicazioni ed investire in settori sottorappresentati.

Condizione	Conteggio
Breast Cancer	82
Coronary Artery Disease	67
Multiple Myeloma	59
Heart Failure	46
Ulcerative Colitis	42
Myelodysplastic Syndromes	35
Lung Cancer	34
Prostate Cancer	33
Acute Myeloid Leukemia	33
Crohn's Disease	31

2.4 Nazione con la media di partecipanti più alta, per tipo di studio

2.4.1 Implementazione della query

Questa analitica serve ad identificare i paesi con la più alta media di partecipanti ai trial, per ogni categoria di studio nel dataset. In particolare:

- Si "esplode" l'array delle informazioni sugli Sponsor/Collaborators.
- Ci si assicura che i valori siano validi.
- Si raggruppa una prima volta per tipo di studio e paese degli sponsor per calcolare la media dei partecipanti.
- Si ordinano i risultati e poi si raggruppa una seconda volta solo per tipo di studio. Con gli operatori "first" e "max" si prende il paese con la media più alta per quel tipo di studio.

```
MATCH (ct: ClinicalTrial)-[cs: HAS_SPONSOR_COLLABORATOR]-(s: SponsorCollaborator)-[sc: IN_COUNTRY]-(co:
WHERE s.NumberOfParticipants IS NOT NULL
AND co.name IS NOT NULL
AND ct.StudyType IS NOT NULL
WITH ct.StudyType AS studyType, co.name AS Country, avg(ct.NumberOfParticipants) AS AvgParticipants
ORDER BY ct.StudyType ASC, AvgParticipants DESC
WITH studyType, COLLECT({country: Country, average: AvgParticipants}) AS countryAvgs
UNWIND countryAvgs[0..1] AS topCountryData
RETURN studyType AS `Study Type`,
topCountryData.country AS `Country`,
topCountryData.average AS `AvgParticipants per StudyType`
ORDER BY `AvgParticipants per StudyType` DESC
LIMIT 20
```

Figure 2.14: Nazione con la media di partecipanti più alta, per tipo di studio - Cypher

```

pipeline_4 = [
    {"$unwind": "$sponsors_collaborators_info"},
    {"$match": {
        "study_type": {"$ne": None, "$ne": "", "$ne": "null"},
        "sponsors_collaborators_info.country": {"$ne": None, "$ne": "", "$ne":
"null"},
        "number_of_participants": {"$ne": None, "$ne": "null", "$type": "number"}}
    },
    {"$group": {
        "_id": {
            "study_type": "$study_type",
            "country": "$sponsors_collaborators_info.country"
        },
        "avg_participants": {"$avg": "$number_of_participants"}}
    },
    {"$sort": {
        "_id.study_type": 1,
        "avg_participants": -1}
    },
    {"$group": {
        "_id": "$_id.study_type",
        "top_country": {"$first": "$_id.country"},
        "highest_avg_participants": {"$first": "$avg_participants"}}
    },
    {"$sort": {"_id": 1}}
]

```

Figure 2.15: Nazione con la media di partecipanti più alta, per tipo di studio - Mongo

2.4.2 Risultati

Questa analitica è utile ad individuare paesi leader per specifiche modalità di ricerca clinica.

Tipo di Studio	Top Paese	Media Partecipanti più Alta
Active surveillance	Italy	115000.0
CCT	Egypt	520.0
Interventional	Iceland	8962.5
Non-interventional	Italy	17.0
Observational	Iceland	804333.3333333334




Figure 2.16: Bar chart - Nazione con la media di partecipanti più alta, per tipo di studio

Dai risultati osserviamo che l'Islanda domina in due categorie:

- *Observational* con una media gigantesca (609.000): probabilmente uno studio nazionale su larga scala.
- *Interventional* con quasi 8.000.

2.5 Città che hanno trattato maggiormente una determinata condizione

2.5.1 Implementazione della query

Questa analitica serve ad identificare per ogni condizione medica, la città che ha condotto il maggior numero di studi clinici.

In particolare:

- Si "esplodono" le condizioni e le informazioni su Sponsor/Collaborators.

- Si filtrano città e condizioni non valide.
- Si fa un primo raggruppamento per condizioni e città degli sponsor per contare gli studi.
- Si ordina e si fa un secondo raggruppamento per condizioni così da prendere la città top.

```
MATCH (con: Condition)-[hc: HAS_CONDITION]-(ct: ClinicalTrial)-[cs:
HAS_SPONSOR_COLLABORATOR]-(s: SponsorCollaborator)-[li: LOCATED_IN_CITY]-(ci: City)
WHERE s.name IS NOT NULL
AND ci.name IS NOT NULL
AND con.name IS NOT NULL
LIMIT 90000
WITH con.name AS Condition, ci.name AS City, ct
WITH Condition, City, count(DISTINCT ct) AS `Count per Condition-City`
ORDER BY `Count per Condition-City` DESC
WITH Condition, COLLECT({city: City, count: `Count per Condition-City`}) AS cityCounts
UNWIND cityCounts[0..1] AS topCityData
RETURN Condition AS `Condition`,topCityData.city AS `City`,topCityData.count AS `Count per
Condition-City`
ORDER BY `Count per Condition-City` DESC
LIMIT 20
```

Figure 2.17: Città che hanno trattato maggiormente una determinata condizione
- Cypher

```

pipeline_5 = [
  {"$unwind": "$conditions"},
  {"$unwind": "$sponsors_collaborators_info"},
  {"$match": {
    "conditions": {"$type": "string", "$ne": ""},
    "sponsors_collaborators_info.city": {"$type": "string", "$ne": ""}},
  {"$group": {
    "_id": {
      "condition": {"$toLower": "$conditions"},
      "city": {"$toLower": "$sponsors_collaborators_info.city"}
    },
    "num_studies": {"$sum": 1}}
  },
  {"$sort": {
    "_id.condition": 1,
    "num_studies": -1}
  },
  {"$group": {
    "_id": "$_id.condition",
    "top_city": {"$first": "$_id.city"},
    "studies_in_top_city": {"$first": "$num_studies"}}
  },
  {"$match": {"studies_in_top_city": {"$gt": 1}}},
  {"$sort": {"studies_in_top_city": -1}},
  {"$limit": 20}
]

```

Figure 2.18: Città che hanno trattato maggiormente una determinata condizione - Mongo

Di seguito viene anche presentato l'implementazione per estrarre il grafico e la sua visualizzazione.

```

query_graph_n5 = """
MATCH (con: Condition)-[hc: HAS_CONDITION]-[ct: ClinicalTrial]-[cs: HAS_SPONSOR_COLLABORATOR]-(s:
SponsorCollaborator)-[li: LOCATED_IN_CITY]-(ci: City)
WHERE s.name IS NOT NULL
AND ci.name IS NOT NULL
AND con.name IS NOT NULL

LIMIT 90000

WITH con.name AS Condition, ci.name AS City, ct
WITH Condition, City, count(DISTINCT ct) AS `Count per Condition-City`

ORDER BY `Count per Condition-City` DESC

WITH Condition, COLLECT({city: City, count: `Count per Condition-City`}) AS cityCounts
UNWIND cityCounts[0..1] AS topCityData

MATCH (fcon: Condition {name: Condition})
-[fhc: HAS_CONDITION]-(fct: ClinicalTrial)
-[fcs: HAS_SPONSOR_COLLABORATOR]-(fs: SponsorCollaborator)
-[fli: LOCATED_IN_CITY]-(fci: City {name: topCityData.city})

RETURN fcon, fhc, fct, fcs, fs, fli, fci
LIMIT 200
"""

graph_n5, error = get_graph_analytics(driver, query_graph_n5)

if error:
    print("Ripetere la query n5, graph vuoto")
else:
    save_graph(graph_n5, 5)

```

Figure 2.19: Città che hanno trattato maggiormente una determinata condizione
- Implementazione Grafo

2.5.2 Risultati

Questo tipo di analitica è molto utile per individuare quelli che sono i centri di eccellenza. Infatti le città evidenziate possono essere considerate hub clinici per specifiche patologie.

Es.:

- Roma per *Leucemia* (99 studi)

Vengono mostrati solo i primi 10 risultati per motivi di spazio.




Figure 2.20: Città che hanno trattato maggiormente una determinata condizione
- Grafo

2.6 Nazioni che sponsorizzano il maggior numero di studi clinici rivolti alle donne

2.6.1 Implementazione della query


L'obiettivo di questa analitica è determinare quali nazioni sponsorizzano più studi clinici dedicati al genere femminile ($Gender == "Female"$), basandosi sulle infor-

Condizione	Top Città	Studi in Top Città
breast cancer	madrid	124
ulcerative colitis	seoul	117
leukemia	rome	99
non-small cell lung cancer	madrid	92
crohn's disease	seoul	90
gastric cancer	seoul	74
stage iiia breast cancer	las vegas	71
multiple myeloma	madrid	70
stage iv lung cancer ajcc v8	las vegas	66

mazioni relative agli sponsor/collaboratori.

In particolare:

- Si filtrano i documenti dove il campo `gender` è `Female`.
- Si esplode l'array di informazione di `Sponsor/Collaboratori`
- Ci si assicura che i campi siano validi.
- Si raggruppa per paese di `Sponsor` e si contano gli studi.
- Si ordina per conteggio in modo decrescente.



```
MATCH (ct: ClinicalTrial)-[cs: HAS_SPONSOR_COLLABORATOR]-(s: SponsorCollaborator)
-[ic: IN_COUNTRY]-(co: Country)
WHERE ct.Gender = 'Female'
AND co.name IS NOT NULL
AND s.name IS NOT NULL
WITH co.name AS Country, count(DISTINCT ct) AS `Count per Country`
ORDER BY `Count per Country` DESC
RETURN Country AS `Country`, `Count per Country`
LIMIT 20
```

Figure 2.21: Nazioni che sponsorizzano il maggior numero di studi clinici rivolti alle donne

2.6.2 Risultati

Analizzando i risultati, notiamo che in questo dataset gli Stati Uniti sono leader nella sponsorizzazione di studi clinici focalizzati sulle donne, con un numero significativamente più alto rispetto agli altri paesi.

```

pipeline_6 = [
  {"$match": {"gender": "Female"}},
  {"$unwind": "$sponsors_collaborators_info"},
  {"$match": {
    "sponsors_collaborators_info.country": {"$type": "string", "$ne": ""}}
  },
  {"$group": {
    "_id": {"$toLower": "$sponsors_collaborators_info.country"},
    "num_studies": {"$sum": 1}}
  },
  {"$sort": {"num_studies": -1}},
  {"$limit": 10}
]

```

Figure 2.22: Nazioni che sponsorizzano il maggior numero di studi clinici rivolti alle donne

Paese	Numero Studi
united states	8028
italy	2230
spain	688
germany	590
france	453
canada	318
united kingdom	318
poland	274
belgium	269
japan	243

2.7 Nazioni che sponsorizzano il maggior numero di studi che coinvolgono minori

2.7.1 Implementazione della query

L'obiettivo dell'analitica è identificare i paesi che partecipano al maggior numero di studi clinici che coinvolgono minori (età < 18 anni), in qualità di sponsor o collaboratori.

In particolare:




Figure 2.23: Map view - Nazioni che sponsorizzano il maggior numero di studi clinici rivolti alle donne

- Si filtrano i documenti dove l'età è < 18 .
- Si esplode l'array di informazioni di Sponsor/Collaborators.
- Ci si assicura che il paese sia una stringa valida.
- Si raggruppa per paese e si fa il conteggio.
- Si ordina per conteggio decrescente.

2.7.2 Risultati

L'analisi dei risultati mostra che anche in questo caso gli Stati Uniti sono in cima, con il maggior numero di studi clinici che coinvolgono minori. Ciò indica la presenza di centri pediatrici di eccellenza e politiche favorevoli alla ricerca su minori.

```

MATCH (ct: ClinicalTrial)-[cs: HAS_SPONSOR_COLLABORATOR]-(s: SponsorCollaborator)
-[ic: IN_COUNTRY]-(co: Country)
WHERE ct.minAgeYears < 18
AND ct.minAgeYears IS NOT NULL
AND s.name IS NOT NULL
AND co.name IS NOT NULL
WITH co.name AS Country, count(DISTINCT ct) AS `Count per Country`
ORDER BY `Count per Country` DESC
RETURN Country AS `Country`, `Count per Country`
LIMIT 20

```

Figure 2.24: Nazioni che sponsorizzano il maggior numero di studi che coinvolgono minori - Cypher

```

pipeline_7 = [
  {"$match": {"age_details.min_years": {"$ne": None, "$lt": 18}}},
  {"$unwind": "$sponsors_collaborators_info"},
  {"$match": {
    "sponsors_collaborators_info.country": {"$type": "string", "$ne": ""}}
  },
  {"$group": {
    "_id": {"$toLower": "$sponsors_collaborators_info.country"},
    "num_studies": {"$sum": 1}
  }},
  {"$sort": {"num_studies": -1}},
  {"$limit": 10}
]

```

Figure 2.25: Nazioni che sponsorizzano il maggior numero di studi che coinvolgono minori - Mongo

Paese	Numero Studi
united states	7987
italy	3079
germany	1679
spain	1462
france	1444
japan	1179
united kingdom	1090
poland	1032
canada	785
australia	686




Figure 2.26: Map View - Nazioni che sponsorizzano il maggior numero di studi che coinvolgono minori

2.8 Città che ricercano più attivamente uno specifico tipo di cancro

2.8.1 Implementazione della query

L'obiettivo dell'analitica è identificare la città che conduce il maggior numero di studi clinici per ciascun tipo di cancro.

In particolare:

- Si esplode l'array dei tipi di cancro.
- Si esplode l'array di informazioni di Sponsors/Collaborators.

- Ci si assicura che i campi siano validi.
- Si raggruppa una prima volta per tipo di cancro e città e si conta per avere il numero di studi per città/cancro.
- Si ordina per tipo di cancro e poi per numero di studi.
- Si raggruppa una seconda volta per tipo di cancro e si prende la città top con relativo conteggio.
- Si ordina per numero di studi.

```
MATCH (ca: CancerType)-[sct: STUDIES_CANCER_TYPE]-(ct: ClinicalTrial)
-[hs: HAS_SPONSOR_COLLABORATOR]-(s: SponsorCollaborator)
-[lis: ]-(sta: State)
WHERE sta.name IS NOT NULL
AND s.name IS NOT NULL
WITH sta.name AS State, ca.name AS CancerType, count(DISTINCT ct) AS `Count
per State`
ORDER BY `Count per State` DESC
WITH CancerType, COLLECT({state: State, count: `Count per State`}) AS
stateCounts
UNWIND stateCounts[0..1] AS topStateData
RETURN CancerType AS `Cancer Type`,
topStateData.state AS `State`,
topStateData.count AS `Count per State`
```

Figure 2.27: Città che ricercano più attivamente uno specifico tipo di cancro - Cypher

2.8.2 Risultati

I risultati di questa analitica sono utili per localizzare i poli di eccellenza clinica oncologica. Possono quindi essere utili a guidare pazienti e ricercatori verso centri

```

pipeline_8 = [
  {"$unwind": "$cancer_types"},
  {"$unwind": "$sponsors_collaborators_info"},
  {"$match": {
    "cancer_types": {"$type": "string", "$ne": ""},
    "sponsors_collaborators_info.city": {"$type": "string", "$ne": ""}}}},
  {"$group": {
    "_id": {
      "cancer_type": {"$toLower": "$cancer_types"},
      "city": {"$toLower": "$sponsors_collaborators_info.city"}
    },
    "num_studies": {"$sum": 1}}
  },
  {"$sort": {
    "_id.cancer_type": 1,
    "num_studies": -1}
  },
  {"$group": {
    "_id": "$_id.cancer_type",
    "top_city": {"$first": "$_id.city"},
    "studies_in_top_city": {"$first": "$num_studies"}}
  },
  {"$match": {"studies_in_top_city": {"$gte": 20}}},
  {"$sort": {"studies_in_top_city": -1}},
  {"$limit": 20}
]

```

Figure 2.28: Città che ricercano più attivamente uno specifico tipo di cancro - Mongo

più attivi e per guidare collaborazioni internazionali focalizzate su specifici tipi di tumori.




Figure 2.29: Bar chart - Città che ricercano più attivamente uno specifico tipo di cancro

Tipo di Cancro	Top Città	Studi in Top Città
leukemia / leukaemia	rome	558
lung cancer	madrid	368
non-hodgkin's lymphoma	milan	296
breast cancer	madrid	287
colon and rectal cancer	rome	168
stomach cancer	seoul	110
liver cancer	london	99
myeloma	rome	94
melanoma	barcelona	92

2.9 Studi clinici che si sono conclusi, con relative condizioni mediche trattate


2.9.1 Implementazione della query

L'obiettivo di questa analitica è trovare tutti gli studi clinici che si sono conclusi (cioè la cui data di fine è anteriore alla data odierna) e identificare le condizioni mediche trattate in ciascuno di essi.

In particolare:

Trial ID	End Date	Conditions
NCT05595642	2025-06-01	Chronic Obstructive Pulmonary Disease (COPD)
NCT05153239	2025-06-01	Relapsed Small Cell Lung Cancer
NCT06174636	2025-06-01	Respiratory Distress Syndrome, Adult
NCT03917173	2025-06-01	Stomach Neoplasms
NCT04591431	2025-06-01	Non Small Cell Lung Cancer
NCT06174636	2025-06-01	Respiratory Failure
NCT03994796	2025-06-01	CDK Gene Mutation
NCT05876754	2025-06-01	Cholangiocarcinoma
NCT03914820	2025-06-01	Colorectal Neoplasms

- Si filtrano i documenti dove la data di fine è minore della data corrente.
- Si esplode l'array delle condizioni e ci si assicura che i valori siano validi.
- Si selezionano i campi di interesse e si ordina per data di fine decrescente.



```

MATCH (ct: ClinicalTrial)-[hc: HAS_CONDITION]-(c: Condition)
WHERE ct.EndDate IS NOT NULL
AND c.name IS NOT NULL
AND date(ct.EndDate) <= date()
ORDER BY ct.EndDate DESC
RETURN ct.TrialID AS `Trial ID`, ct.EndDate, c.name AS `Condition`
LIMIT 20

```

Figure 2.30: Studi clinici che si sono conclusi, con relative condizioni mediche trattate - Cypher

2.9.2 Risultati

Questa analitica è utile poichè fornisce una visione storica ed immediata degli ultimi sviluppi clinici.

Vengono mostrate solo le prime 10 righe per motivi di spazio.

```

pipeline_9 = [
    {"$match": {"end_date": {"$ne": None, "$lt":
current_date}}, "$conditions"},
    {"$match": {"conditions": {"$type": "string", "$ne":
""}}}, {"$project": {
    "_id": 0,
    "Trial ID": "$_id",
    "End Date": "$end_date",
    "Conditions": "$conditions"
    }},
    {"$sort": {"End Date": -1}},
    {"$limit": 20}
]

```

Figure 2.31: Studi clinici che si sono conclusi, con relative condizioni mediche trattate - Mongo

2.10 Studi clinici con maggiore visibilità mediatica (Altmetric score)

2.10.1 Implementazione della query

L'obiettivo di questa analitica è identificare gli studi con maggiore impatto mediatico, misurato tramite l'Altmetric Attention Score, e associarli alle condizioni mediche trattate.

In particolare:

- Si filtrano i documenti dove l'altmetric score è valido.
- Si esplode l'array di condizioni e ci si assicura che i valori siano validi.
- Si ordina per score in modo decrescente.

```

MATCH (ct:ClinicalTrial)-[:HAS_CONDITION]->(cond:Condition)
WHERE ct.AltmetricAttentionScore IS NOT NULL AND ct.AltmetricAttentionScore
RETURN ct.TrialID AS TrialID,
       ct.Title AS Title,
       ct.AltmetricAttentionScore AS AltmetricScore,
       cond.name AS Condition
ORDER BY ct.AltmetricAttentionScore DESC
LIMIT 20

```

Figure 2.32: Studi clinici con maggiore visibilità mediatica - Cypher

```

pipeline_10 = [
  {"$match": {"altmetric_attention_score": {"$ne": None, "$type":
"number"}, "conditions": {"$type": "string", "$ne": ""}}},
  {"$sort": {"altmetric_attention_score": -1}},
  {"$limit": 20},
  {"$project": {
    "_id": 0,
    "Trial ID": "$_id",
    "Title": "$title",
    "Altmetric Score": "$altmetric_attention_score",
    "Condition": "$conditions"}
  }
]

```

Figure 2.33: Studi clinici con maggiore visibilità mediatica - Mongo

Anche in questa query è stato deciso di implementare l'estrazione del grafo, con relativa visualizzazione.



```
query_graph_n10 = """
MATCH (ct:ClinicalTrial)-[r_hc:HAS_CONDITION]->(cond:Condition)
WHERE ct.AltmetricAttentionScore IS NOT NULL AND ct.AltmetricAttentionScore > 0
WITH ct, r_hc, cond, ct.AltmetricAttentionScore AS score
ORDER BY score DESC
LIMIT 20
RETURN ct, r_hc, cond
"""

graph, error = get_graph_analytics(driver, query_graph_n10)

if error:
    print("Ripetere la query n10, graph vuoto")
else:
    if not os.path.exists(os.path.join(result_path, "graphs")):
        os.makedirs(os.path.join(result_path, "graphs"))
    save_graph(graph, 10)
```

Figure 2.34: Studi clinici con maggiore visibilità mediatica - Implementazione Grafo




Figure 2.35: Studi clinici con maggiore visibilità mediatica - Grafo

2.10.2 Risultati

Questa analitica è interessante poichè mostra gli studi più discussi nel panorama scientifico e mediatico e quindi le condizioni cliniche che attirano maggiore attenzione pubblica.

Trial ID	Altmetric Score	Condtion
NCT02819635	1283.0	Ulcerative Colitis (UC)
NCT03104400	1247.0	Psoriatic Arthritis
NCT03105128	1129.0	Crohn's Disease
NCT04292899	1081.0	COVID-19
NCT03398148	1061.0	Ulcerative Colitis (UC)
NCT03398135	1030.0	Ulcerative Colitis (UC)
NCT03569293	1010.0	Atopic Dermatitis
NCT03671148	962.0	Psoriatic Arthritis (PsA)
NCT03345836	955.0	Crohn's Disease
NCT03345823	861.0	Crohn's Disease

Table 2.1: La colonna relativi ai Titoli è omessa per leggibilità




Figure 2.36: Bar chart orizzontale - Studi clinici con maggiore visibilità mediatica


2.11 Condizioni con media più alta di Altmetric Score

2.11.1 Implementazione della query

Questa analitica ha l'obiettivo di mostrare le condizioni mediche associate agli studi clinici, che in media, hanno ottenuto la maggior visibilità sui media, secondo il punteggio Altmetric Attention Score.

In particolare:

- Si filtrano i documenti dove l'altmetric score è valido.
- Si esplode l'array di condizioni e si verifica che i valori siano validi.
- Si raggruppa per condizione e si calcola la media di altmetric score.



```

MATCH (cond:Condition)<-[:HAS_CONDITION]-(ct:ClinicalTrial)
WHERE ct.AltmetricAttentionScore IS NOT NULL AND ct.AltmetricAttentionScore
WITH cond, avg(ct.AltmetricAttentionScore) AS avg_altmetric_score
RETURN cond.name AS Condition, avg_altmetric_score
ORDER BY avg_altmetric_score DESC
LIMIT 20

```

Figure 2.37: Condizioni con media più alta di Altmetric Score - Cypher

- Si ordina per media calcolata in modo decrescente.

2.11.2 Risultati

Dai risultati notiamo che anche in questo caso il COVID-19 è la condizione che ha ricevuto più attenzione mediatica.

Condition	Average Altmetric Score
ulcerative colitis (uc)	985.0
psoriatic arthritis (psa)	962.0
aml arising from myelodysplastic syndrome (mds)	834.0
newly diagnosed acute myeloid leukemia (aml)	834.0
untreated aml	834.0
kras p, g12c mutated /advanced metastatic nslc	788.0
breast diseases	784.0
central nervous system neoplasms	784.0
brain neoplasms	784.0

```

pipeline_11 = [
  {"$match": {"altmetric_attention_score": {"$ne": None, "$type":
"number"}}},
  {"$match": {"conditions": {"$type": "string", "$ne": ""}}},
  {"$group": {
    "_id": {"$toLower": "$conditions"},
    "avg_altmetric_score": {"$avg": "$altmetric_attention_score"}}
  },
  {"$sort": {"avg_altmetric_score": -1}},
  {"$limit": 20},
  {"$project": {
    "_id": 0,
    "Condition": "$_id",
    "Average Altmetric Score": "$avg_altmetric_score"}
  }
]

```

Figure 2.38: Condizioni con media più alta di Altmetric Score - Mongo

2.12 Nazioni delle organizzazioni finanziatrici che hanno sponsorizzato il maggior numero di studi clinici

2.12.1 Implementazione della query

L'obiettivo è identificare i paesi delle organizzazioni finanziatrici che hanno sponsorizzato il maggior numero di studi clinici.

In particolare:

- Si espone l'array di informazioni sui collaborating funders e si verifica che i valori siano validi.
- Si raggruppa per paese e si conta.





Figure 2.39: Bar chart orizzontale Condizioni con media più alta di Altmetric Score

- Si ordina per conteggio decrescente.




```

MATCH (country:Country)<-[:IN_COUNTRY]-(funder:Funder)<-[:FUNDED_BY]-
(funder_info:Info) WHERE funder_info IS NOT NULL AND country.name <> ''
RETURN country.name AS Country, count(DISTINCT ct) AS NumberOfTrials
ORDER BY NumberOfTrials DESC
LIMIT 20

```

Figure 2.40: Nazioni delle organizzazioni finanziatrici che hanno sponsorizzato il maggior numero di studi clinici - Cypher



```

pipeline_12 = [
  {"$unwind": "$collaborating_funders_info"},
  {"$match": {"collaborating_funders_info.country": {"$type": "string", "$ne": ""}}},
  {"$group": {
    "_id": {"$toLower": "$collaborating_funders_info.country"},
    "num_studies": {"$sum": 1}}
  },
  {"$sort": {"num_studies": -1}},
  {"$limit": 10},
  {"$project": {
    "_id": 0,
    "Country": "$_id",
    "Number of Studies": "$num_studies"}
  }
]

```

Figure 2.41: Nazioni delle organizzazioni finanziatrici che hanno sponsorizzato il maggior numero di studi clinici - Mongo

2.12.2 Risultati

Questa analitica può essere utile per enti di ricerca e università ad identificare paesi con elevata attività di finanziamento con cui collaborare.

Country	Number of Studies
united states	1159
italy	1048
germany	183
japan	140
united kingdom	116
belgium	96
switzerland	80
netherlands	55
france	43
denmark	25

I risultati mostrano che gli Stati Uniti emergono come il paese con il maggior numero di studi sponsorizzati (1159), superando di poco l'Italia.

2.13 Ricercatori/Contatti più attivi con relativa patologia più studiata

2.13.1 Implementazione della query

L'obiettivo di questa analitica è identificare i ricercatori/contatti più attivi negli studi clinici e determinare per ciascuno la condizione medica più frequentemente studiata.

In particolare:

- Si esplode sia l'array degli investigatori sia quello delle condizioni.
- Si filtra per valori validi.
- Si raggruppa una prima volta per investigatori e condizioni per contare il numero di studi relativi alla coppia.
- Si ordinano i valori.
- Si raggruppa una seconda volta per investigator e si prende la top condizione con relativo conteggio.
- Si ordina per studi totali per investigatore.

2.13.2 Risultati

Questa analitica è utile per identificare esperti in base all'area terapeutica, così da proporre collaborazioni di ricerca.

```

MATCH (inv:InvestigatorContact)<-[:HAS_INVESTIGATOR_CONTACT]-(ct:ClinicalTrial)-
[:HAS_CONDITION]->(cond:Condition)
WHERE inv.name IS NOT NULL AND inv.name <> "" AND cond.name IS NOT NULL AND cond.name <>
WITH inv, cond, count(ct) AS studiesForThisCondition
ORDER BY inv.name, studiesForThisCondition DESC
WITH inv, sum(studiesForThisCondition) AS totalStudiesByInvestigator,
collect({condition_node: cond, count: studiesForThisCondition}) AS conditionCounts
RETURN inv.name AS Investigator, totalStudiesByInvestigator AS TotalStudies,
      (conditionCounts[0]).condition_node.name AS TopCondition,
      (conditionCounts[0]).count AS StudiesOnTopCondition
ORDER BY TotalStudies DESC
LIMIT 20

```

Figure 2.42: Ricercatori/Contatti più attivi con relativa patologia più studiata - Cypher

Investigator	Total Studies	Top Condition	Studies for Top Condition
jennifer a. dorth	82	anal canal squamous cell carcinoma	1
charles shideman	80	prostate adenocarcinoma	2
tyler gunter	78	prostate adenocarcinoma	2
jack j. hong	77	postneoadjuvant therapy stage iiib gastroesophageal	1
abbvie inc	74	crohn's disease	8
bryan a. faller	73	stage iiib lung cancer ajcc v8	3
michael d. chuong	73	clinical stage iib esophageal adenocarcinoma ajcc v8	1
jordan kharofa	73	pathologic stage ii esophageal squamous cell carcinoma ajcc v8	1
shane lloyd	73	clinical stage ii esophageal squamous cell carcinoma ajcc v8	1
kathleen j. yost	68	stage iiib lung cancer ajcc v8	2

2.14 Top collaborazioni dell'Università di Napoli Federico II con enti finanziatori

2.14.1 Implementazione della query

L'obiettivo di questa analitica è determinare quali enti finanziatori o collaboratori hanno partecipato più frequentemente a sperimentazioni cliniche in partnership con l'AOU Federico II.

In particolare:

- Si filtrano i documenti dove AHC == "AOUSSN_FEDERICOII".
- Si esplode l'array di informazioni su Sponsor/Collaborators e ci si assicura

```

pipeline_13 = [
  {"$unwind": "$investigators_contacts"},
  {"$unwind": "$conditions"},
  {"$match": {
    "investigators_contacts": {"$type": "string", "$ne": ""},
    "conditions": {"$type": "string", "$ne": ""}
  }},
  {"$group": {
    "_id": {
      "investigator": {"$toLower": "$investigators_contacts"},
      "condition": {"$toLower": "$conditions"}
    },
    "num_studies_for_condition": {"$sum": 1}}
  },
  {"$sort": {
    "_id.investigator": 1,
    "num_studies_for_condition": -1}
  },
  {"$sort": {
    "_id.investigator": 1,
    "num_studies_for_condition": -1}
  },
  {"$group": {
    "_id": "$_id.investigator",
    "top_condition": {"$first": "$_id.condition"},
    "studies_for_top_condition": {"$first": "$num_studies_for_condition"},
    "total_studies_by_investigator": {"$sum":
"$num_studies_for_condition"}}
  },
  {"$sort": {"total_studies_by_investigator": -1}},
  {"$limit": 20},
  {"$project": {
    "_id": 0,
    "Investigator": "$_id",
    "Total Studies": "$total_studies_by_investigator",
    "Top Condition": "$top_condition",
    "Studies for Top Condition": "$studies_for_top_condition"}
  }
]

```

Figure 2.43: Ricercatori/Contatti più attivi con relativa patologia più studiata - Mongo



```

MATCH (c: Condition)-[hc: HAS_CONDITION]-(ct: ClinicalTrial)
-[hic: HAS_INVESTIGATOR_CONTACT]-(i: InvestigatorContact)
WHERE c.name IS NOT NULL
WITH c.name AS Condition, i.name AS Investigator, count(ct) AS `Count per Condition`
ORDER BY `Count per Condition` DESC
WITH Investigator, COLLECT({condition: Condition, count: `Count per Condition`}) AS
topConditionData, collect(distinct i.name) AS topConditionData
RETURN Investigator AS `Investigator`,
topConditionData.condition AS `Top Condition`,
topConditionData.count AS `Number of Studies`
ORDER BY `Number of Studies` DESC
LIMIT 20

```

Figure 2.45: Top collaborazioni dell'Università di Napoli Federico II con enti finanziatori - Cypher

```

federico_ii_ahc_name = "AOUSSN_FEDERICOOII"
pipeline_14 = [
  {"$match": {"ahc": federico_ii_ahc_name}},
  {"$unwind": "$sponsors_collaborators_info"},
  {"$match": {"sponsors_collaborators_info.name": {"$type": "string", "$ne": ""}}},
  {"$group": {
    "_id": "$sponsors_collaborators_info.name",
    "num_collaborations": {"$sum": 1}}
  },
  {"$sort": {"num_collaborations": -1}},
  {"$limit": 20},
  {"$project": {
    "_id": 0,
    "Sponsor/Collaborator": "$_id",
    "Number of Collaborations": "$num_collaborations"
  }}
]

```

Figure 2.46: Top collaborazioni dell'Università di Napoli Federico II con enti finanziatori - Mongo




Figure 2.47: Bar chart - Top collaborazioni dell'Università di Napoli Federico II con enti finanziatori

University Hospital" stesso: questo conferma che molte sperimentazioni sono registrate con l'ospedale come centro promotore e come centro partecipante. Tuttavia vediamo comparire anche molti altri ospedali italiani ed internazionali.

2.15 Top collaborazione per ente finanziatore

2.15.1 Implementazione della query

L'obiettivo di questa analitica è trovare, per ciascun finanziatore principale (*Main Funder*), l'organizzazione finanziatrice con cui collabora più frequentemente (*Collaborating Funder*) in progetti clinici, mostrando il numero di collaborazioni.

In particolare:

- Si esplode l'array *funder_groups* e lo si rinomina in *main_funder_group*
- Si esplode anche quello dei collaborating funders.
- Ci si assicura che i nomi siano validi e si filtrano via i casi in cui il main funder e il collaborating funder siano uguali.
- Si raggruppa una prima volta per main funder e collaborating funder per contare il numero di collaborazioni.
- Si ordina e si raggruppa una seconda volta per main funder group prendendo il *top_collaborating_funder* e il relativo conteggio delle collaborazioni.
- Si ordina per conteggio decrescente.

2.15.2 Risultati

Questa analitica è utile per mettere in luce relazioni forti e consolidate tra enti finanziatori. Ciò può essere di supporto ad enti di ricerca che possono utilizzare queste informazioni per migliorare le proprie possibilità di finanziamento orientandosi verso network già esistenti.

```

MATCH (mainFG:FunderGroup)-[:BELONGS_TO_FUNDER_GROUP]-(ct:ClinicalTrial)-[:FUNDED_BY]-
(collabF:FunderGroup)
WHERE (collabF.name IS NOT NULL AND mainFG.name <> ""
      AND collabF.name IS NOT NULL AND collabF.name <> ""
      AND mainFG.name <> collabF.name)
WITH mainFG, collabF, count(DISTINCT ct) AS collabCount
ORDER BY mainFG.name, collabCount DESC
WITH mainFG, collect({collaborator_node: collabF, count: collabCount}) AS collabData
RETURN mainFG.name AS MainFunderGroup,
       (collabData[0]).collaborator_node.name AS TopCollaborator,
       (collabData[0]).count AS collabCount
ORDER BY collabCount DESC
LIMIT 20

```

Figure 2.48: Top collaborazione per ente finanziatore - Cypher

Main Funder Group	Top Collaborating Funder	Number of Collaborations
us federal funders	national cancer institute	105
icrp - international cancer research partnership	national cancer institute	105
nih - national institutes of health	national cancer institute	105
amrc - association of medical research charities	european organisation for research and treatment of cancer	59
coalition s	european commission	25
ec & erc - european union	european commission	25
hra - health research alliance	washington university in st. louis	3
nihr - national institute for health research	national institute for health and care research	1
dod - united states department of defense	alliance for clinical trials in oncology	1
ukri - uk research and innovation	european organisation for research and treatment of cancer	1

```

pipeline_16 = [
  {"$unwind": "$funder_groups"},
  {"$unwind": "$collaborating_funders_info"},
  {"$match": {
    "funder_groups": {"$type": "string", "$ne": ""},
    "collaborating_funders_info.name": {"$type": "string", "$ne": ""}
  }},
  {"$project": {
    "main_funder": {"$toLower": "$funder_groups"},
    "collaborating_funder": {"$toLower": "$collaborating_funders_info.name"}
  }},
  {"$match": {"$expr": {"$ne": ["$main_funder", "$collaborating_funder"]}}},
  {"$group": {
    "_id": {
      "main_funder": "$main_funder",
      "collaborating_funder": "$collaborating_funder"
    },
    "collab_count": {"$sum": 1}
  }},
  {"$sort": {
    "_id.main_funder": 1,
    "collab_count": -1
  }},
  {"$group": {
    "_id": "$_id.main_funder",
    "top_collaborating_funder": {"$first": "$_id.collaborating_funder"},
    "num_collaborations_with_top": {"$first": "$collab_count"}
  }},
  {"$sort": {"num_collaborations_with_top": -1}},
  {"$limit": 20},
  {"$project": {
    "_id": 0,
    "Main Funder Group": "$_id",
    "Top Collaborating Funder": "$top_collaborating_funder",
    "Number of Collaborations": "$num_collaborations_with_top"
  }
}
]

```

Figure 2.49: Top collaborazione per ente finanziatore - Mongo




Figure 2.50: Bar chart - Top collaborazione per ente finanziatore